

# Capítulo 11 — Introdução à Regressão

## Modelo de Regressão Linear Simples

Um modelo de regressão deste tipo traduz a relação entre uma variável quantitativa independente,  $X$ , e uma variável quantitativa dependente,  $Y$ , nos termos seguintes:

$$Y_n = \alpha + \beta \cdot (X_n - \bar{X}) + E_n$$

(modelo alternativo:  $Y_n = \alpha' + \beta \cdot X_n + E_n$ , com  $\alpha' = \alpha - \beta \cdot \bar{X}$ )

em que:

- $n$ : índice denotando as observações do par de variáveis  $X$  e  $Y$  ( $n = 1, 2, \dots, N$ )
- $\bar{X}$ : média aritmética das observações  $X_n$
- $E_n$ : erro aleatório associado ao valor observado  $Y_n$

### Estimativas de $\alpha$ e $\beta$

$$\hat{\alpha} = a = \frac{1}{N} \cdot \sum_n y_n = \bar{y}$$

$$\hat{\beta} = b = \frac{S_{XY}}{S_{XX}}$$

com,

$$S_{XY} = \sum_n [(X_n - \bar{X}) \cdot (Y_n - \bar{Y})]$$

$$S_{XX} = \sum_n (X_n - \bar{X})^2$$

$$S_{YY} = \sum_n (Y_n - \bar{Y})^2$$

### Intervalos de Confiança a $(1 - \gamma) \cdot 100\%$ para os parâmetros $\alpha'$ , $\alpha$ e $\beta$

Parâmetro $\alpha$	$A \pm t_{N-2}(\gamma/2) \cdot S \cdot \sqrt{\frac{1}{N}}$
Parâmetro $\alpha'$ (ordenada na origem do eixo dos $XX$ )	$(A - \bar{X} \cdot B) \pm t_{N-2}(\gamma/2) \cdot S \cdot \sqrt{\frac{1}{N} + \frac{\bar{X}^2}{S_{XX}}}$
Parâmetro $\beta$	$B \pm t_{N-2}(\gamma/2) \cdot S \cdot \sqrt{\frac{1}{S_{XX}}}$

Notas:  $A$  e  $B$  são os estimadores de  $\alpha$  e  $\beta$ , respectivamente;

$S^2$  é um estimador de  $\sigma^2$  e é dado por  $S^2 = \frac{1}{N-2} \cdot \sum_n [Y_n - A - B \cdot (X_n - \bar{X})]^2$

$\sigma^2$  pode também ser estimado a partir do  $DQMR$  da tabela ANOVA (ver detalhes mais abaixo):  $DQMR = \frac{S_{YY} - B \cdot S_{XY}}{N-2}$

Testes de Hipóteses aos parâmetros $\alpha'$ , $\alpha$ e $\beta$	
Hipóteses	Estatística de Teste
$H_0: \alpha = \alpha_0$ $H_1: \alpha \neq \alpha_0, \alpha > \alpha_0$ ou $\alpha < \alpha_0$	$ET = \frac{A - \alpha_0}{S/\sqrt{N}}$  Quando $H_0$ é verdadeira, $ET$ segue uma distribuição $t_{N-2}$
Hipóteses	Estatística de Teste
$H_0: \alpha' = \alpha'_0$ $H_1: \alpha' \neq \alpha'_0, \alpha' > \alpha'_0$ ou $\alpha' < \alpha'_0$	$ET = \frac{(A - \bar{X} \cdot B) - \alpha'_0}{S \cdot \sqrt{\frac{1}{N} + \frac{\bar{X}^2}{S_{XX}}}}$  Quando $H_0$ é verdadeira, $ET$ segue uma distribuição $t_{N-2}$
Hipóteses	Estatística de Teste
$H_0: \beta = \beta_0$ $H_1: \beta \neq \beta_0, \beta > \beta_0$ ou $\beta < \beta_0$	$ET = \frac{B - \beta_0}{S/\sqrt{S_{XX}}}$  Quando $H_0$ é verdadeira, $ET$ segue uma distribuição $t_{N-2}$

Teste de Hipótese ao parâmetro $\beta$ baseado na tabela ANOVA (ver tabela ANOVA no final do formulário)	
Hipóteses	Estatística de Teste
$H_0: \beta = \beta_0$ $H_1: \beta \neq \beta_0$	$ET = \frac{DQMDR}{DQMR}$  Quando $H_0$ é verdadeira, $ET$ segue uma distribuição $F_{1,N-2}$

### Previsões com base no modelo de regressão linear simples

O valor de uma variável dependente,  $Y$ , pode ser obtida a partir do novo valor da variável  $X$  dependente. Para isto recorre-se à seguinte expressão para a melhor previsão de  $Y$ :

$$\hat{Y} = \hat{\mu}_Y = A + B \cdot (X - \bar{X})$$

A variância do erro de previsão ( $\delta$ ) é dada por:

$$Var(\delta) = \left[ 1 + \frac{1}{N} + \frac{(X - \bar{X})^2}{S_{XX}} \right] \cdot \sigma^2$$

Intervalos de Confiança a  $(1 - \gamma) \cdot 100\%$  para a previsão

Para valores de $Y$	$\hat{Y} \pm t_{N-2}(\gamma/2) \cdot S \cdot \sqrt{1 + \frac{1}{N} + \frac{(X-\bar{X})^2}{S_{XX}}}$
Para valores de $\mu_Y$	$\hat{Y} \pm t_{N-2}(\gamma/2) \cdot S \cdot \sqrt{\frac{1}{N} + \frac{(X-\bar{X})^2}{S_{XX}}}$

Correlação entre Variáveis

A análise da correlação entre variáveis é uma técnica muito semelhante à regressão no que se refere aos objectivos. No entanto, esta é menos potente, não indicando a forma como as variáveis estão relacionadas.

Coefficiente de Correlação Amostral	$R_{XY} = \frac{S_{XY}}{\sqrt{S_{XX}} \cdot \sqrt{S_{YY}}}$
Coefficiente de Correlação Populacional	$\rho_{XY} = \frac{E[(X - \mu_X) \cdot (Y - \mu_Y)]}{\sqrt{E[(X - \mu_X)^2] \cdot E[(Y - \mu_Y)^2]}}$
Coefficiente de Determinação	$R_{XY}^2 = \frac{B^2 \cdot S_{XX}}{S_{YY}}$

Regressão Não Linear

Os modelos não lineares que traduzem relações entre a variável dependente e uma só variável independente podem ser convertidos em modelos lineares por aplicação de transformações às variáveis dependente ou independente. Seguem-se exemplos de modelos onde a linearização é facilmente obtida:

Modelo Original	Novas Variáveis	Modelo Linearizado
$Y_n = \alpha' + \frac{\beta}{X_n} + E_n$	$U_n = \frac{1}{X_n}$	$Y_n = \alpha' + \beta \cdot U_n + E_n$
Modelo Exponencial $Y_n = e^{\alpha' + \beta \cdot X_n + E_n}$	$Z_n = \ln Y_n$	$Z_n = \alpha' + \beta \cdot X_n + E_n$
Modelo “Curva em S” (com $\alpha' > 0$ e $\beta < 0$ ) $Y_n = e^{\alpha' + \beta/X_n + E_n}$	$U_n = \frac{1}{X_n} \quad Z_n = \ln Y_n$	$Z_n = \alpha' + \beta \cdot U_n + E_n$

Tabela ANOVA para Teste de Hipótese ao parâmetro  $\beta$  baseado na tabela ANOVA

Fontes de Variação	Variações (Somas de desvios quadráticos)	Graus de Liberdade (Nº de termos independentes)	Desvios Quadráticos Médios (DQMs)	Valores Esperados
Devida à Regressão (DR)	(Variação “explicada” pela regressão) $VDR = B^2 \cdot S_{XX}$ $= B \cdot S_{XY}$	$GL_1 = 1$	$DQMDR = VDR$	$E[DQMDR] = \sigma^2 + \beta^2 \cdot S_{XX}$
Residual (R)	(Variação residual “não explicada”) $VR = S_{YY} - B \cdot S_{XY}$	$GL_2 = N - 2$	$DQMR = \frac{VR}{GL_2}$	$E[DQMR] = \sigma^2$
Total (T)	(Variação total) $VT = S_{YY}$	$GL = GL_1 + GL_2 = N - 1$		

Formulário adaptado de:  
Estatística  
Rui Campos Guimarães, José A. Sarsfield Cabral  
Verlag Dashöfer